



SISTEMAS PERICIAIS

EXPERT SYSTEMS

Inteligência Artificial

Joaquim Filipe

SISTEMAS PERICIAIS VS. INFORMÁTICA CONVENCIONAL

- Razão de ser dos sistemas periciais
 - Sistemas de apoio à decisão
 - Meta-modelos da realidade?
- Decisão/Ação
 - Informação ou conhecimento?
 - Sintaxe vs. semântica vs. pragmática
- Resolução de problemas
 - Complexos, sem solução algorítmica
 - Usando heurísticas, i.e. conhecimento humano
 - Modelos vs. Teorias

ALGORITMO

- Sequência finita de instruções bem definidas, não ambíguas, para resolver um problema particular num intervalo de tempo finito com uma quantidade de esforço finito.

(Introdução à Informática, usando o Pascal – Pavão Martins)

INTELIGÊNCIA ARTIFICIAL

- A Inteligência Artificial interessa-se por desenvolver máquinas para resolver problemas em que de momento os seres humanos são melhores.

(Artificial Intelligence, Elaine Rich)

PROBLEMA

- Frequentemente as pessoas são capazes de resolver problemas para os quais não existe uma solução algorítmica conhecida.
- Nesses casos a informática convencional tem um problema.
- É necessário recorrer a técnicas de IA

MODELOS

- A realidade é demasiado complexa.




➔ É necessário usar modelos para interagir com a realidade e resolver problemas.

EXEMPLOS

- Sistema de produção de papel da PORTUCEL
 - Diagnóstico de avarias
 - Modelos físicos são possíveis mas demasiado complexos
 - Modelos físicos dos processos não são usados na prática
 - Em vez disso usam-se modelos heurísticos.
- Sistema Financeiro
 - Gestão de carteiras de ativos
 - Modelos matemáticos são falíveis devido à complexidade do mercado e à subjetividade dos agentes
 - A utilização desses modelos assenta em pressupostos que nem sempre são válidos (vide crises bolsistas)
 - Em vez disso usa-se modelos de preferências e de utilidade, os quais são subjetivos e nem sempre coerentes

TEORIAS VS. MODELOS

- Um modelo é uma simplificação da realidade.
- Uma teoria é um modelo internamente consistente em termos sintáticos, i.e. não contém contradições.
 - E a **Semântica**?
- Uma boa teoria deve ser **válida**, i.e. deve ser um modelo semanticamente consistente.



A TEORIA E A PRÁTICA

- *Não há nada mais prático do que uma boa teoria.*



Nothing is more practical than a good theory.

~ Ludwig Boltzmann

AZ QUOTES

Uma boa teoria deverá ter poder *descritivo* e *prescritivo* e por isso ajudar a *compreender a realidade* e a *resolver problemas*.

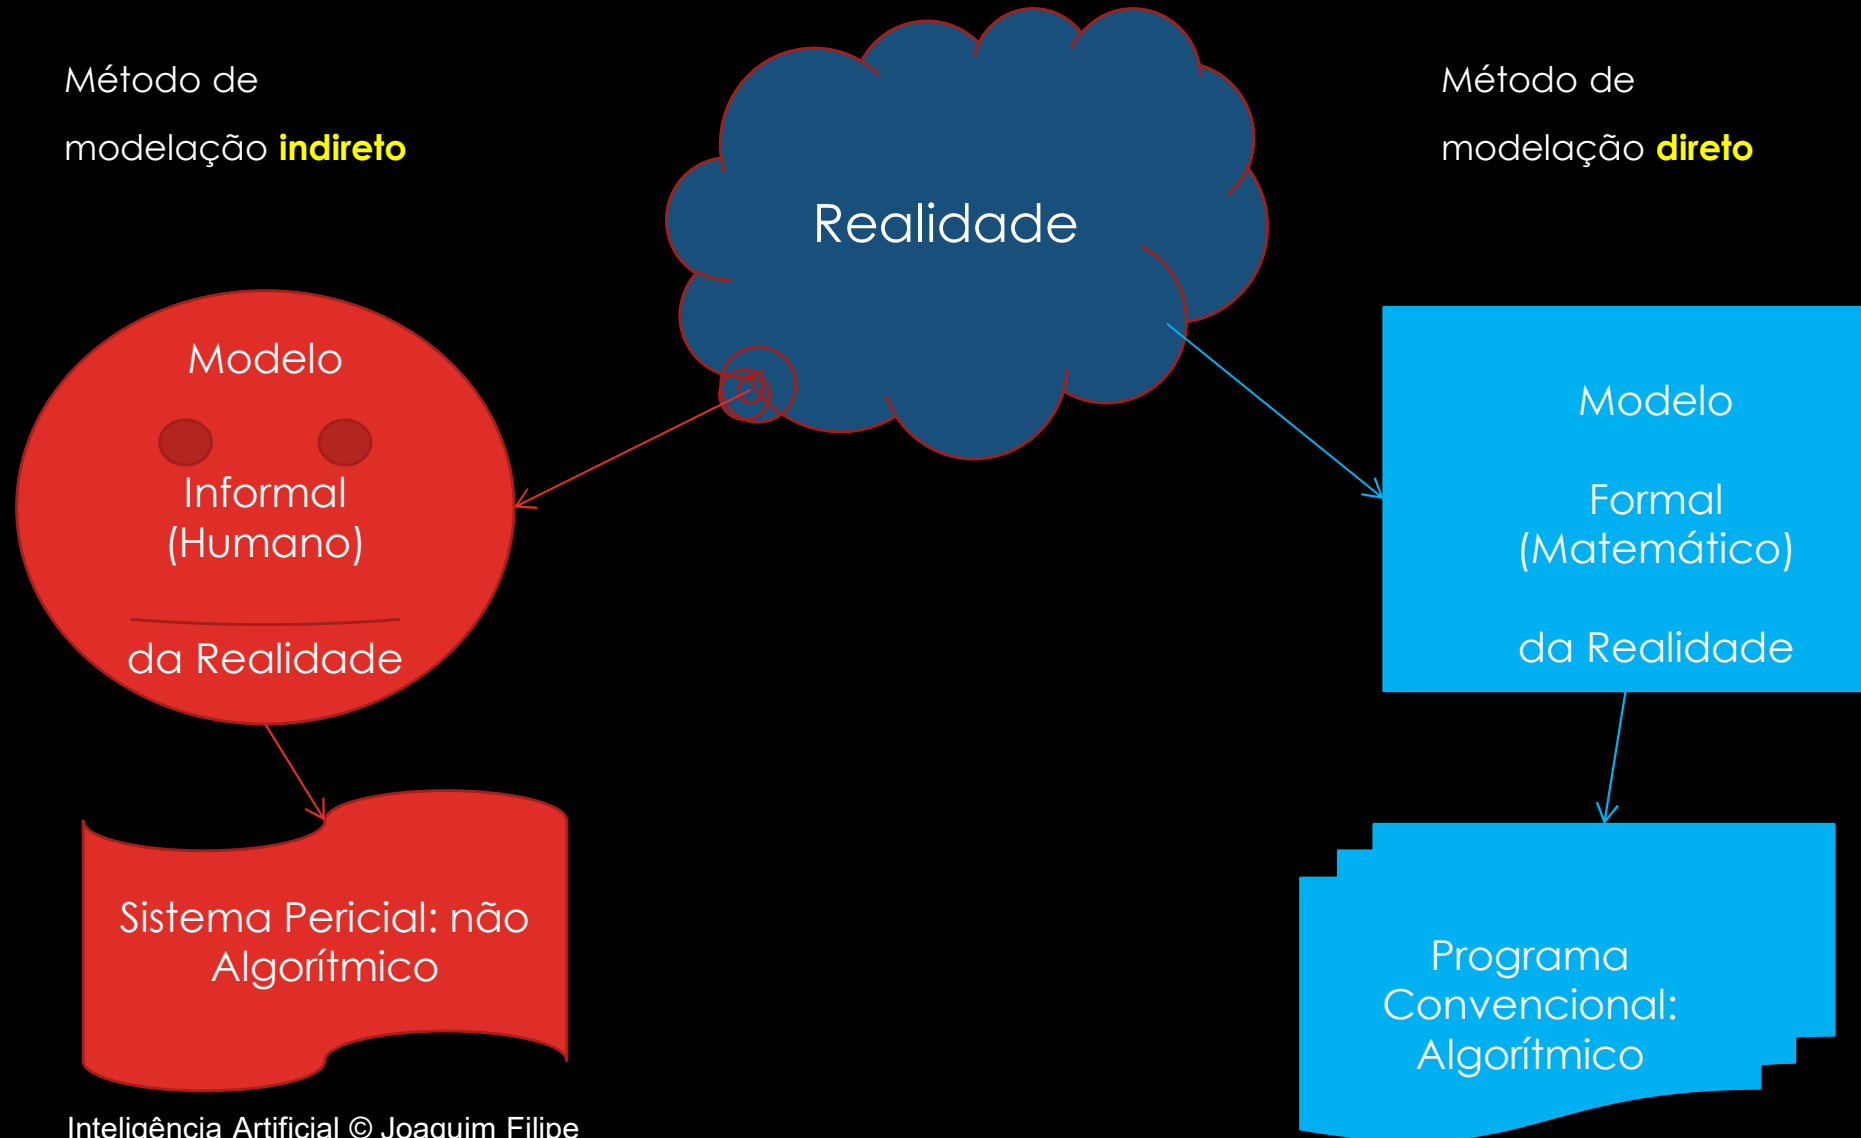
RESOLUÇÃO DE PROBLEMAS

- Dilema sobre a abordagem à resolução de problemas:
 - A) modelar a realidade?
 - Conhecimento rigoroso (teórico)
 - Aplicar algoritmos que oferecem soluções rigorosas.
 - B) modelar a forma como a pessoa vê a realidade?
 - Conhecimento empírico
 - Aplicar heurísticas

SISTEMA PERICIAL: UM META-MODELO?¹¹

Método de
modelação **indireto**

Método de
modelação **direto**



MODELAÇÃO INDIRETA DO CONHECIMENTO DO ESPECIALISTA



O Especialista




A Realidade

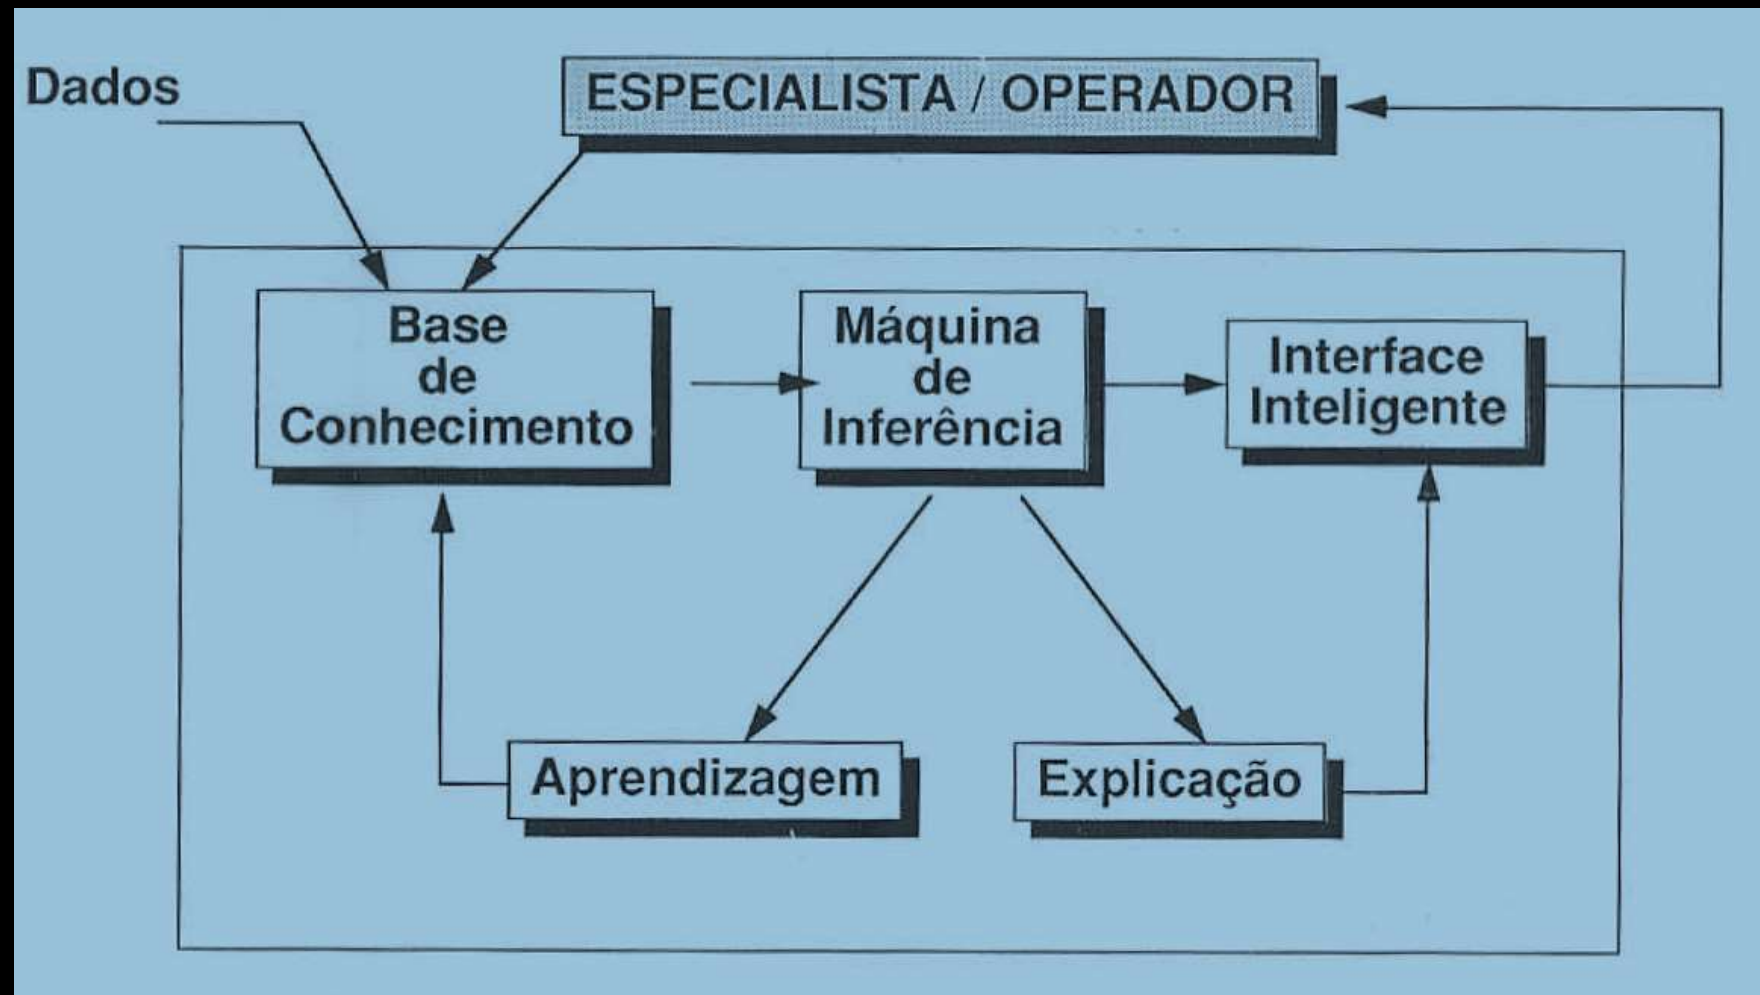
Conhecimento
Simbólico:
Factos, Regras
Raciocínio Lógico



O Sistema Pericial



ARQUITETURA



CARACTERISTICAS DOS PRINCIPAIS COMPONENTES

- Base de Conhecimento:
 - Contém os modelos de domínio
 - Factos e Regras
 - Dependente do domínio
 - Hipótese do “mundo fechado”
 - Natureza essencialmente declarativa
- Máquina de Inferência
 - Contém os mecanismos lógicos de raciocínio
 - Independente do domínio
 - Natureza essencialmente procedimental

EXPLICAÇÃO

- Um sistema pericial pode errar, na medida em que:
 - Reflete o conhecimento de seres humanos (ainda que especialistas no domínio de aplicação)
 - Pode ter uma base de conhecimento incompleta
- Necessário providenciar mecanismos de validação ao utilizador do sistema
- O módulo de explicação indica a sequência de regras aplicadas pelo sistema e respetiva instanciação com factos presentes na base de conhecimento

EXEMPLOS: MYCIN

- Desenvolvido em Stanford / Ed. Shortliffe et al. 1970's
- Objetivos:
 - Diagnóstico de infecções bacteriológicas
 - Prescrição de terapia baseada no diagnóstico
- Características:
 - Bloco de notas ativo
 - Modelo do especialista humano / Não substitui o especialista
 - Diálogo em formato de linguagem natural, próximo do especialista
 - Desempenho verificável, comparável ao dos especialistas

EXCERTO DE DIÁLOGO

10) Do you suspect Pt538 may have an infection at a site from which you have not obtained culture specimens?

-- No

11) Information about current antimicrobial:

Drug name: Cephalotin

Route of administration: IV

Date started: 23-jan-77

12) Are there other antimicrobials?

** No

13) Are there prior antimicrobials?

** No

[Considering organisms which might be present...]

14) Has Pt538 recently had symptoms of persistent headache or other abnormal neurologic symptoms (dizziness, lethargy, etc.)?

** Yes

15) Has Pt538 recently had objective evidence of abnormal neurologic signs (nuchal rigidity, coma, seizures, etc.) documented by physician observation or examination?

**Yes

[The CSF cultures will be considered to be associated with MENINGITIS.]

16) Please give the date on which clinical evidence (symptoms, signs, or laboratory tests) of the meningitis first appeared.

** 29-Jan-77 22:15

DIPMETER ADVISOR

- Schlumberger / Luc Steels 1977
- Objetivos:
 - Interpretação de medições geofísicas
 - Identificação de estruturas baseadas em compostos orgânicos (petróleo, gás, etc.)
- Características:
 - Bloco de notas ativo
 - Permite análise detalhada de partes do problema
 - Interface visual diretamente utilizável pelo especialista

EXEMPLO DE REGRA

Distributary fan rule

IF:

- 1) Delta-dominated marine zone
- 2) Continental-shelf marine zone
- 3) Sand zone intersecting marine zone
- 4) Blue pattern in intersection

THEN:

Distributary fan with
Top of fan equal to top of blue pattern
Bottom of fan equal to
bottom of blue pattern
Direction of flow equal to
azimuth of blue pattern.

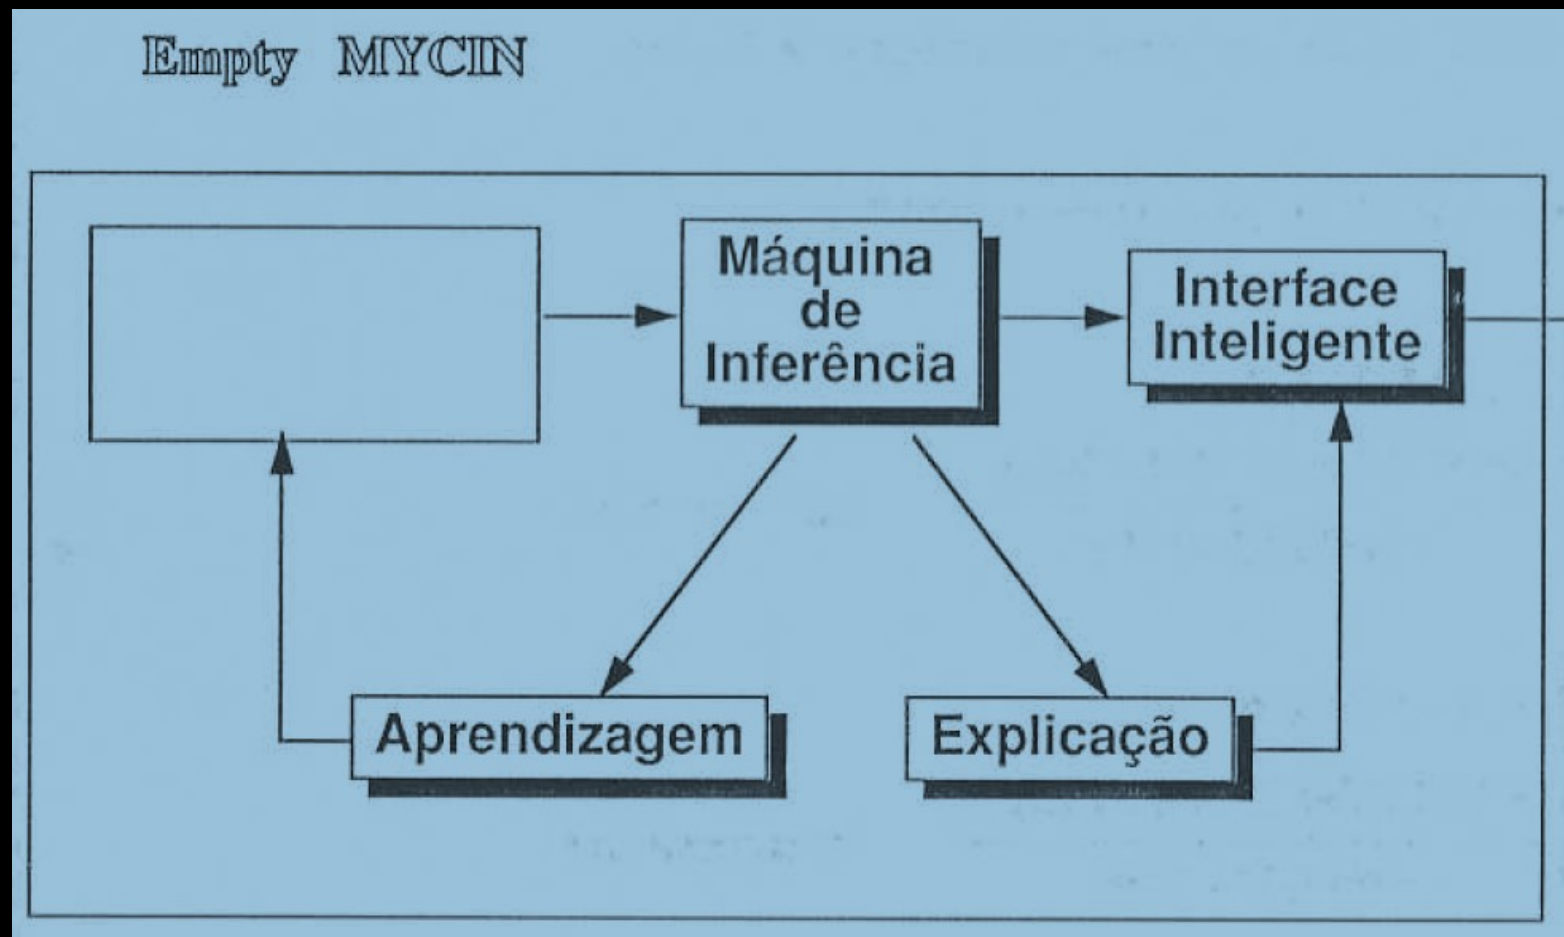
XCON

- Carnegie-Mellon Uni. / John Mc Dermott 1978 para a Digital Equipment Corporation (DEC)
- Objetivos:
 - Configuração de computadores da família VAX
- Características:
 - Problema complexo:
 - Mais de 400 componentes só para o VAX 11/780
 - Mais de 5,000 regras e mais de 20,000 componentes
 - Pioneiro na área de SPs aplicados à tecnologia
 - Elevado sucesso prático
 - Mais de US\$25 milhões em poupanças por ano

AUTHORIZER'S ASSISTANT

- American Express (AMEX)
- Desenvolvido pela Inference Corp (agora MindBox) em 1988
- Esteve em produção contínua e em desenvolvimento desde essa altura.
- Aplica-se agora a todos os produtos da AMEX.
- Contém mais de 35,000 regras
- Aumento de 20% na produtividade
- Redução em 33% do crédito não concedido
- Elevado ROI

EMYCIN



SHELLS

- Ferramentas de desenvolvimento de sistemas periciais
- Análogas às ferramentas CASE
- Aplicáveis a qualquer domínio
- Permitem a reutilização da máquina de inferência, dado que esta é:
 - De natureza sintática
 - Independente do domínio de aplicação
- Exige a construção da base de conhecimento, dado que esta é:
 - De natureza semântica
 - Dependente do domínio de aplicação

SHELLS

- **JESS** – Java Expert System Shell

Sandia National Labs (fundado em 1940 para realizar o projeto Manhattan)

<http://herzberg.ca.sandia.gov/>

- **CLIPS** – C Language Integrated Production System

NASA's Johnson Space Center (de 1985 a 1996)


<http://clipsrules.sourceforge.net/>

- **EXSYS** – Expert System Software and Services

<http://www.exsys.com/>

- E muitas outras: <http://www.kbsc.com/rulebase.html>

RACIOCÍNIO LÓGICO EM SISTEMAS PERICIAIS



INFERÊNCIA/RACIOCÍNIO LÓGICO EM GERAL

- Raciocínio **dedutivo**
 - Usando o **silogismo lógico**
 - Resultados garantidamente válidos
 - Análogo às relações entre conjuntos (A contém B)
- Raciocínio **indutivo**
 - Usando formas de generalização/extrapolação
 - Resultados não são garantidamente válidos
- Raciocínio **abduativo**
 - Usando as observações para procurar uma explicação provável
 - Frequentemente usado em medicina
 - Resultados não são garantidamente válidos

$P \rightarrow Q$

$Q \rightarrow R$

Então: $P \rightarrow R$

QUANTAS LÓGICAS?

- **Proposicional ou de ordem zero:** conjunto de expressões sintáticas (fórmulas bem formadas, ou fbfs) atômicas. Exemplo: $A \wedge B$
- **Predicativo ou de primeira ordem:** fbfs são quantificáveis e decomponíveis em termos
 - **Termos:** constantes, variáveis e predicados (funções booleanas que podem receber variáveis como argumentos).
 - Exemplo: $\forall_x \text{homem}(x) \rightarrow \text{mortal}(x)$
- **Modal ou de ordem superior:** fbfs incluem predicados de ordem superior.
 - Um predicado de ordem superior tem um ou mais predicados como argumentos. Em geral, um predicado de ordem superior de ordem n toma um ou mais predicados de ordem $(n - 1)$ como argumentos, onde $n > 1$.

BASE DO RACIOCÍNIO DEDUTIVO

- Silogismo Lógico
 - Equivalente a:
 - **Modus Ponens**

$$\begin{array}{l} P \rightarrow Q \\ P \\ \hline \therefore Q \end{array}$$

Quando chove há nuvens no céu
Está a chover
 Então: há nuvens no céu

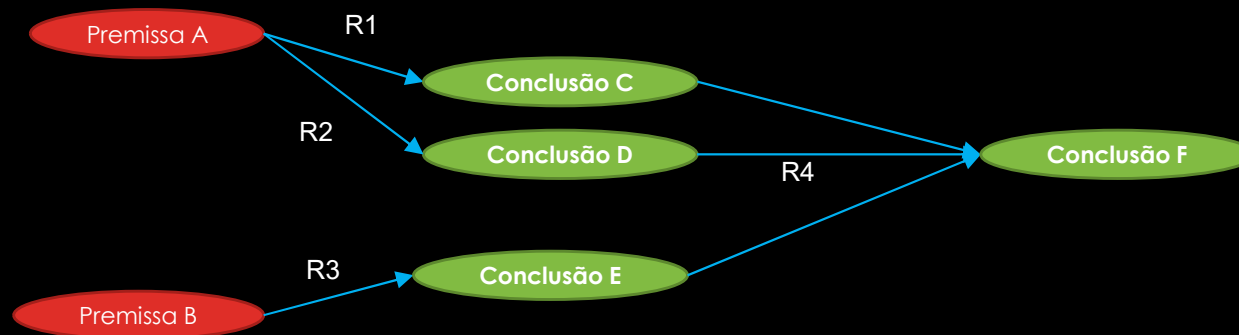
- **Modus Tollens** (lei da contraposição / redução ao absurdo)

$$\begin{array}{l} P \rightarrow Q \\ \sim Q \\ \hline \therefore \sim P \end{array}$$

Quando chove há nuvens no céu
Não há nuvens no céu
 Então: não está a chover

ENCADEAMENTO PARA A FRENTE

- O raciocínio dedutivo pode encadear regras de dois modos:
 - Modo dirigido por dados (*data driven*)
 - Encadeamento para a frente (*forward chaining*)



Base de factos:

Facto A

➔ Facto C (R1)

➔ Facto D (R2)

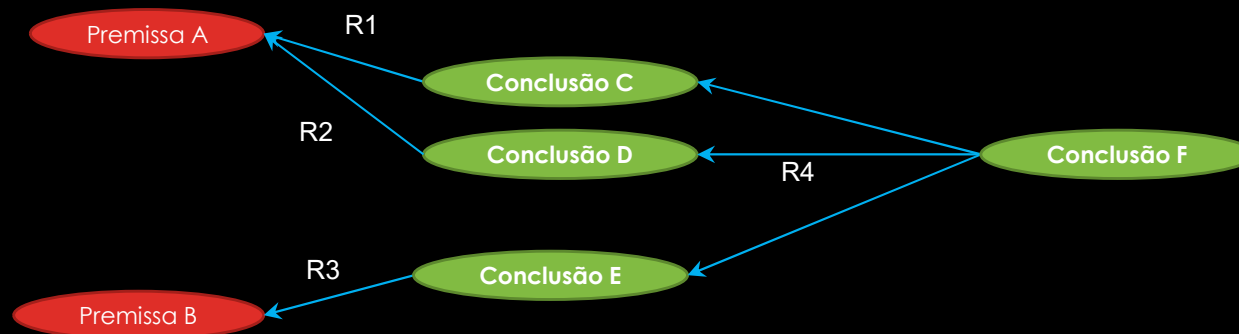
Facto B

➔ Facto E (R3)

➔ Facto F (R4)

ENCADEAMENTO PARA TRÁS

- Modo dirigido por objetivos (goal driven)
- Encadeamento para trás (backward chaining)
- Começa por se colocar uma hipótese, a qual se tenta demonstrar com dados-base (*ground data*)



Base de factos:

Facto A
Facto B

Hipótese F
← C, D, E
Hipótese C
← A (base)
Hipótese D
← A (base)
Hipótese E
← B (base)

SISTEMAS DE PRODUÇÃO

- Sistema computacional baseado em regras de comportamento (de produção).
- Cada regra de produção tem duas partes:
 - IF (precondição sensorial ou premissa)
 - THEN (ação ou conclusão)
- Se uma precondição satisfaz (*matching*) o estado corrente do mundo, então a ação da regra é “disparada” (*fired*).
- A precondição também é designada por “Lado esquerdo” (left-hand side, LHS) e a ação por “Lado direito” (right-hand side, RHS)



Post 1941

FACTOS, PADRÕES E REGRAS

BASE DE CONHECIMENTO

Factos

(homem Socrates)

+

As variáveis têm nomes
começados por ?

Regras

(R1

(homem ?x) => (mortal ?x))

LHS => RHS

(homem ?x) é um Padrão

CONCEITOS BÁSICOS DO PROCESSO DE INFERÊNCIA

- Memória permanente ou memória de longo prazo (modelos de domínio)
- Memória de trabalho ou memória de curto prazo (modelos de caso)
- Ciclo de encadeamento para a frente:
 - emparelhar
 - activar
 - resolver conflito
 - disparar.



EMPARELHAMENTO (MATCHING)

- O emparelhamento é feito elemento a elemento, por ordem.
 - Constante ~ Constante
 - Variável ~ Variável ou Constante (mediante uma substituição adequada)
- O resultado do emparelhamento de um padrão com um facto é uma substituição (de variáveis)
- Exemplo:
 - $(a \text{ ?}x \text{ ?}y) \sim (a \ b \ c) \rightarrow ((\text{?}x \ b) (\text{?}y \ c))$

ATIVAÇÃO DE REGRAS

- Se o lado esquerdo emparelhar com um ou mais factos na base de conhecimento, então a regra é ativada.
- Exemplo

Regra R1:

$$(a \text{ ?x } c) (b) \Rightarrow (d \text{ ?x })$$

- Factos na Base de Conhecimento:

F1: (a); F2: (a b c); F3: (b)

- A regra R1 é ativada com a substituição: $((\text{?x } b))$

RESOLUÇÃO DE CONFLITOS

- Um conflito surge quando várias regras podem ser activadas simultaneamente;
- Nesse caso é preciso escolher uma regra para “disparar”.
- A escolha é determinada por critérios heurísticos (por exemplo: regra com maior número de premissas)

DISPARAR UMA REGRA

- Se uma regra activada é seleccionada para ser disparada, então:
- Identifica-se a lista de substituições possíveis.
- Selecciona-se uma das substituições
- Depois de aplicada a devida substituição, o lado direito da regra é inserido na memória de trabalho do sistema.
- Exemplo: a Regra R1: $(a \text{ ?}x \text{ } c) (b) \Rightarrow (d \text{ ?}x)$, com a substituição $((\text{?}x \text{ } b))$ leva a que seja inserida na memória de trabalho do sistema pericial o facto $(d \text{ } b)$.

COMPLEXIDADE DO PROCESSO DE INFERÊNCIA

- Admitindo R regras, P padrões por regra (em média) e F factos, a complexidade computacional seria de $O(RF^P)$

Exemplo:

Possibilidades de combinação: $9=3^2$

Regra r1

Factos:

Padrões: p1, p2

f1, f2, f3

f1, f1

f2, f1

f3, f1

f1, f2

f2, f2

f3, f2

f1, f3

f2, f3

f3, f3

- BC estável => maioria dos testes seriam repetidos.
- Ineficiência elevada

PRINCIPAIS CONCEITOS A RETER

- Raciocínio: encadeamento de regras
 - 2 modos, ambos dedutivos: para a frente (baseado em factos) e para trás (baseado em objetivos)
- A aplicação de uma regra implica
 - O matching (emparelhamento) dos padrões da regra com os factos que constam na base de conhecimento: **constantes emparelham com constantes iguais**; **variáveis emparelham com quaisquer constantes ou variáveis**.
 - Depois da ativação de todas as regras é preciso escolher (mediante um processo de resolução de conflitos) a que vai de facto ser aplicada (disparada)
- O processo é complexo, baseado num ciclo que se repete até não haver ativação de regras, em que o número de operações de comparação na fase de matching é da ordem de RF^P


EXEMPLO

- Base de conhecimento:
 - Regras
 - R1: $\text{pai}(?x, ?y), \text{pai}(?y, ?z) \Rightarrow \text{avô}(?x, ?z)$
 - R2: $\text{pai}(?x, ?y), \text{irmão}(?x, ?z) \Rightarrow \text{tio}(?z, ?y)$
 - Factos:
 - F1: $\text{pai}(\text{Manuel}, \text{José})$
 - F2: $\text{pai}(\text{José}, \text{Ana})$
 - F3: $\text{irmão}(\text{Manuel}, \text{António})$
- Raciocínio dedutivo em encadeamento para a frente:
 - $F1, F2 + R1 \rightarrow \text{F4: avô(Manuel, Ana)}$
 - $F1, F3 + R2 \rightarrow \text{F5: tio(António, José)}$

EXERCICIO

- Considere o contexto das relações familiares.
 1. Escreva um conjunto de regras do tipo $A \rightarrow B$ que permitam definir todas as relações familiares de que se lembre, por forma a permitir a inserção de um modelo das relações familiares na base de conhecimento de um sistema pericial.
 2. Adicione factos à base de conhecimento para permitir que estes em conjunção com as regras anteriormente definidas possam ser usados pela máquina de inferência do sistema para deduzir, em modo encadeamento para a frente, que José é sobrinho de António.

EFICIÊNCIA DOS SISTEMAS DE PRODUÇÃO



ENQUADRAMENTO

- RETE ~ rede em Latim.
- Charles Forgy (1982)



- A ineficiência antes referida é aliviada através da manutenção em memória dos resultados dos testes anteriores.
- Shells: OPS5, ART, CLIPS, JESS, etc.

JUSTIFICAÇÃO DA EFICIÊNCIA

- Explora 2 aspetos comuns nos sistemas baseados em regras:
 - Redundância temporal: poucos factos criados por uma regra ser disparada; poucas regras afectadas por esses novos factos.
 - Similaridade estrutural: mesmo padrão aparece no LHS de mais de uma regra.

ESTRUTURA DE DADOS DE SUPORTE


- Grafo dirigido acíclico:
 - **Nós**: representam padrões (excepto a raíz)
 - **Caminhos** da raíz para as folhas representam padrões nos LHSs de regras.
 - Em cada nó está a informação acerca dos factos satisfeitos pelos padrões.

TIPOS DE NÓS NO RETE


- 3 tipos de nó:
 - Nó raíz,
 - Nó padrão (tipo 1) (*alfa*) e
 - Nó junção (tipo 2) (*beta*).
- **Nó raíz:** tem como sucessores nós tipo 1
 - Cada padrão em cada regra dá origem a um nó alfa tipo 1.
 - A memória alfa tem tantas colunas quantas as variáveis de um nó alfa.
- Os **nós beta** são construídos com base nos nós alfa e em outros nós beta, dando origem a uma memória beta.

NÓS BETA

- A construção de nós beta segue a seguinte metodologia: Para cada regra R_i
 - $B_{i,2}$ deriva de $A_{i,1}$ e $A_{i,2}$.
 - $B_{i,j}$, para $j > 2$, deriva de $B_{i,j-1}$ e $A_{i,j}$.




RACIOCÍNIO INEXATO



LÓGICA SEM INCERTEZA

- Lógica Booleana
 - 2 valores lógicos (falso e verdade / 0 e 1)
 - Conectivas lógicas: \wedge (conjunção), \vee (disjunção) e \sim (negação).
 - Regra de inferência: Modus Ponens ou Modus Tollens
- Cálculos Lógicos / Álgebras booleanas:
 - Proposicional ou de ordem zero
 - Predicativo ou de primeira ordem
 - Modal ou de ordem superior
- No entanto ...
 - no mundo real existe incerteza e portanto os valores lógicos verdade/falso não são em geral suficientes para criar boas teorias.



George Boole
(1815-1864)

FONTES DE INCERTEZA

- Incerteza em relação à validade do conhecimento contido na base de conhecimento, nomeadamente as **regras** de inferência.
 - Exemplo: $(\exists x \text{ cão}) (\exists x \text{ ladra}) \Rightarrow (\exists x \text{ não morde})$
Qual o grau de confiança?
- Incerteza em relação à validade dos **dados** introduzidos no sistema pericial.
 - Exemplo: se o sistema perguntar (João velho)? A resposta poderá ser sim ou não mas com um grau de confiança dependente da idade do João.

MODELAÇÃO DA INCERTEZA

- Incerteza **subjativa**
 - Lógica “Fuzzy”
 - Raciocinio qualitativo
- Incerteza **objetiva**
 - Probabilidades – lei de Bayes
 - Inferência estatística para atualizar a confiança numa hipótese de cada vez que se faz uma observação
 - Factores de confiança
 - Simplificação da lei de Bayes, assumindo independência estatística


LÓGICA FUZZY

- Esta abordagem permite tratar a incerteza associada quer às regras quer aos dados.
 - Origem: Lotfi Zadeh, 1965.
- Ideia basilar:
 - uma instância é um conceito se pertencer ao conjunto de todas as instâncias do mesmo.
 - O conjunto é geralmente definido intensionalmente, usando uma função de pertença Booleana (0=não; 1=sim)
 - Zadeh propõe a utilização de uma função de pertença com contradomínio no intervalo $[0, 1]$; 0=não; 1=sim; todos os restantes valores representam diferentes níveis de incerteza.




HARD SETS VS. FUZZY SETS

Hard Set



$$p_1 \in C_1 ? \dots \{0, 1\}$$

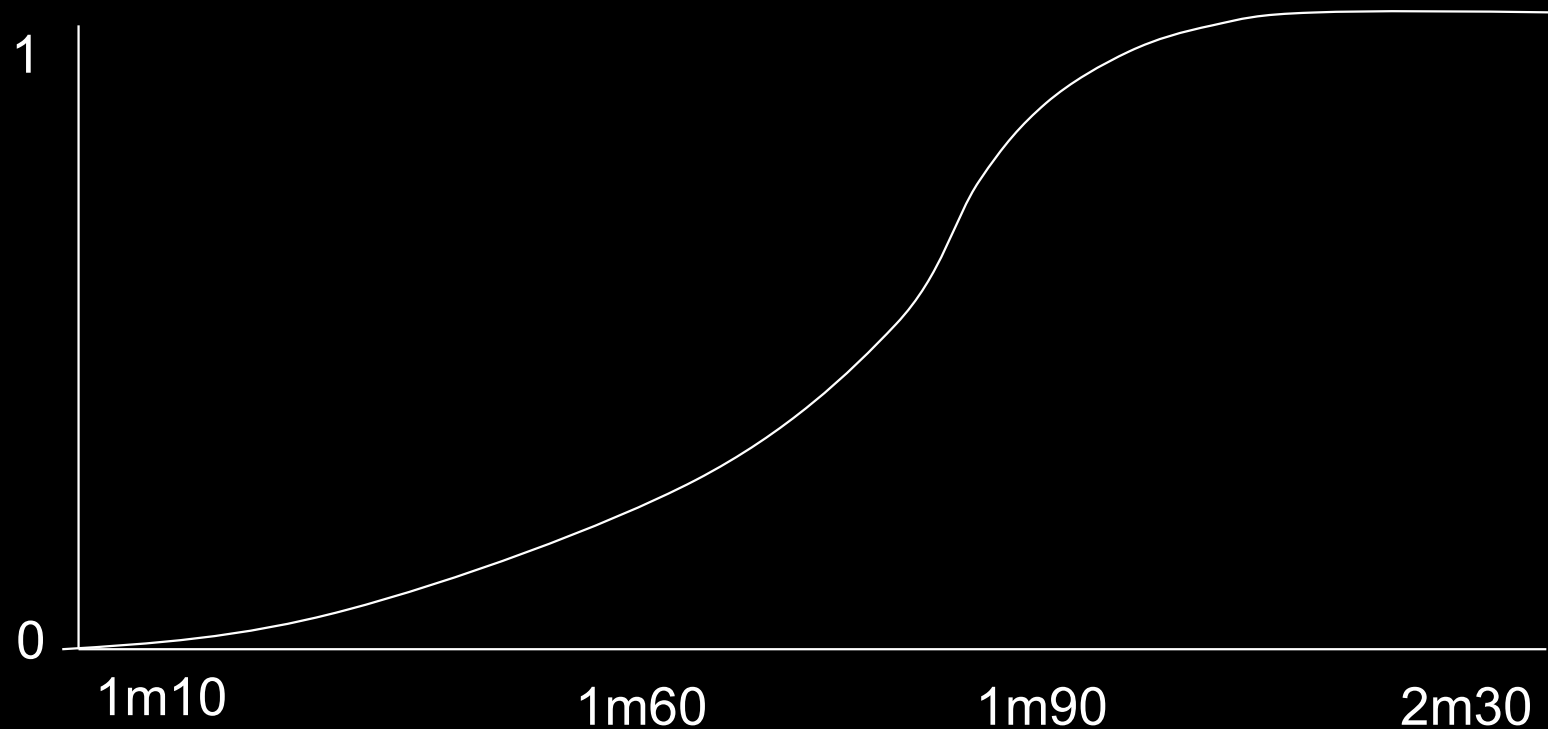
Fuzzy set



$$p_2 \in C_2 ? \dots [0, 1]$$

EXEMPLO

Conceito qualitativo: "Pessoa Alta"



O João tem 1.90 Valor lógico (fuzzy) = 0,86

COMBINAÇÃO DE VALORES LÓGICOS FUZZY

- **NEGAÇÃO:**

Em lógica booleana: se A é verdade $\sim A$ é falso e vice-versa

A	$\sim A$
0	1
1	0

- Em lógica *fuzzy* se o valor fuzzy de uma premissa i é $f(i)$ então a negação é dada por $f(\sim i) = 1 - f(i)$

CONJUNÇÃO

- **CONJUNÇÃO**

- Em lógica booleana, a conjunção segue a seguinte tabela de verdade:

P	Q	$P \wedge Q$
0	0	0
0	1	0
1	0	0
1	1	1

- Em lógica *fuzzy*, a conjunção tem como valor lógico o **mínimo** dos valores lógicos das proposições elementares.

DISJUNÇÃO

- **DISJUNÇÃO**

- Em lógica booleana, a disjunção segue a seguinte tabela de verdade:

P	Q	$P \vee Q$
0	0	0
0	1	1
1	0	1
1	1	1

- Em lógica *fuzzy*, a conjunção tem como valor lógico o **máximo** dos valores lógicos das proposições elementares

ABORDAGEM BAYESIANA

- Pretende-se identificar a melhor hipótese (i.e. a mais provável), dentre um conjunto H de hipóteses, que é justificada por um conjunto D de dados.

$$h = \arg \max_{h \in H} P(h | D)$$



Thomas Bayes
1701-1761

- Na interpretação Bayesiana “probabilidade” é uma medida do “grau de crença” (não necessariamente coincidente com a frequência relativa)
- O teorema de Bayes relaciona o grau de crença numa proposição antes e depois de uma observação.

TEOREMA DE BAYES

- $P(D)$: probabilidade *a priori* de ocorrência dos dados D (*factos observados*)
- $P(h)$: probabilidade *a priori* de ocorrência da hipótese h (*conclusão*)
(notar que $P(h)$ é uma medida do nosso conhecimento do problema).
- $P(D | h)$: probabilidade *a priori* de que, dada uma hipótese h , se observe o conjunto de dados D .
- Quer-se conhecer a probabilidade *a posteriori* $P(h | D)$.

$$P(h | D) = \frac{P(D | h)P(h)}{P(D)}$$

O teorema de Bayes permite efetuar o cálculo da probabilidade *a posteriori* em termos das probabilidades *a priori*.

FACTORES DE CONFIANÇA (CERTAINTY FACTORS)

- A utilização de fatores de confiança representa uma simplificação do método de Bayes, que só é válida se existir independência estatística entre as observações.
- Método da União
 - A probabilidade de uma conclusão ser válida havendo possibilidade de a obter por uma de duas vias é dada pela probabilidade de ocorrência de um de dois eventos A ou B:
 - $P(A \text{ ou } B) = P(A) + P(B) - P(A \text{ e } B)$
 - Presume-se normalmente **a independência estatística** das diferentes contribuições. Portanto: $P(A \text{ e } B) = P(A) \cdot P(B)$.
 - Logo: $P(A \text{ ou } B) = P(A) + P(B) - P(A) \cdot P(B) = P(A) + P(B) \cdot (1 - P(A))$


FACTORES DE CONFIANÇA (CERTAINTY FACTORS)

- Método da União

- Este método permite ultrapassar o problema indicado para a lógica fuzzy.
- Considere-se duas regras, R_1 e R_2 , que concluem o mesmo com diferentes graus de confiança: $cf_1=0.2$; $cf_2=0.5$.
- O factor de confiança na conclusão é:

$$\begin{aligned} cf(\text{conclusão}) &= cf_1 + cf_2 - cf_1 \cdot cf_2 \\ &= cf_1 + cf_2 (1 - cf_1) \end{aligned}$$

- No exemplo presente $cf(\text{conclusão})=0.6$.



- Notar que

- o cf cresce incrementalmente, sem nunca atingir o valor 1.
- **Presume-se a independência estatística** das diferentes contribuições.

- Cálculo do fator de confiança da conclusão de uma regra


$$cf_k = RI_k(cf).[R_k(cf)]$$

Em que:

$R_k(cf)$ é o fator de confiança da regra k

$RI_k(cf)$ é o fator de confiança composto das premissas (inputs) da regra k

DESENVOLVIMENTO DE SISTEMAS PERICIAIS



ENGENHARIA DE SISTEMAS PERICIAIS

- Incerteza elevada
- Feito à medida



- ROI exigido elevado

→ Ciclo de vida: espiral

ESCOLHA DO DOMÍNIO DE APLICAÇÃO

- Características fundamentais:
 - Utilização de conhecimento especializado
 - Necessidade de abordagem não-convencional
 - Disponibilidade de especialistas no domínio
 - Elevada valorização da captura do conhecimento especializado
 - Aceitável obtenção de sucesso limitado
- Tipo de tarefa:
 - Requer principalmente raciocínio simbólico
 - Requer utilização de heurísticas
 - Envolve um leque de conhecimentos estreito e não senso comum

PARTICIPANTES NO DESENVOLVIMENTO

- Especialista:
 - Fornece conhecimento teórico e empírico do domínio
 - Critica o sistema pericial à medida que se desenvolve
- Engenheiro do conhecimento
 - Conhece as tecnologias de Sistemas Periciais
 - Adquire, codifica e insere o conhecimento do especialista numa base de conhecimento
 - Treina os utilizadores do sistema
- Utilizador
 - Critica as funcionalidades e a usabilidade do sistema à medida que este se desenvolve
 - Ajuda a compreender a aplicação do sistema em contexto real



AQUISIÇÃO DE CONHECIMENTO

INTRODUÇÃO

- A fase de aquisição de conhecimento é simultânea com a fase de representação de conhecimento.
- Frequentemente considerado o estrangulamento principal no processo de construção de sistemas periciais.
- Tipicamente necessária a interacção humana (semelhante ao que acontece com programação heurística e sistemas de suporte à decisão).
- Duas abordagens principais, em sistemas periciais baseados em regras:
 - Aquisição directa dos especialistas do domínio
 - Aquisição através de registos históricos, por indução de regras.

AQUISIÇÃO ATRAVÉS DE UM ESPECIALISTA NO DOMÍNIO

- 4 razões porque a aquisição directa através do especialista no Domínio pode não resultar:
 - Pode não haver um especialista no Domínio.
 - Os alegados especialistas podem exhibir um desempenho pobre a medíocre.
 - Os especialistas podem não querer revelar os seus “segredos” profissionais.
 - Os especialistas podem não ser capazes de articular o método de resolução de problemas que usam.

O ENGENHEIRO DO CONHECIMENTO E O ESPECIALISTA

- Por vezes o engenheiro do conhecimento torna-se um especialista no domínio. Por exemplo: o XCON. J.McDermott usou alguns manuais de configuração do VAX para, com um esforço de cerca de 3 pessoas-mês produzir um protótipo com 250 regras.
 - Argumento contra: tipicamente é necessário cerca de 10 anos para uma pessoa se tornar um especialista, mediante a aquisição de 50,000 a 100,000 heurísticas.
- Alternativamente pode usar-se o especialista como engenheiro do conhecimento: abordagem comum em pequenos sistemas periciais pessoais.
 - Problemas: custo de formação e custo de oportunidade.

INDUÇÃO DE REGRAS

- Alternativa a usar um especialista humano: converter uma base de dados existente num conjunto de regras de produção.
- A base de dados deve ter exemplos pertinentes ao problema em causa, cuja resolução foi considerada adequada (exemplos de boas decisões).
- A geração automática de regras (indução) permite geralmente produzir pelo menos um bom primeiro protótipo.

EXEMPLO

- Para ilustrar a abordagem usa-se o problema da identificação de aeronaves, dentre um universo contendo apenas 4 tipos, para simplificar a compreensão do método.

- **C130**

- **C5A**



- **C141**

- **B747**



OBJECTOS, ATRIBUTOS E VALORES

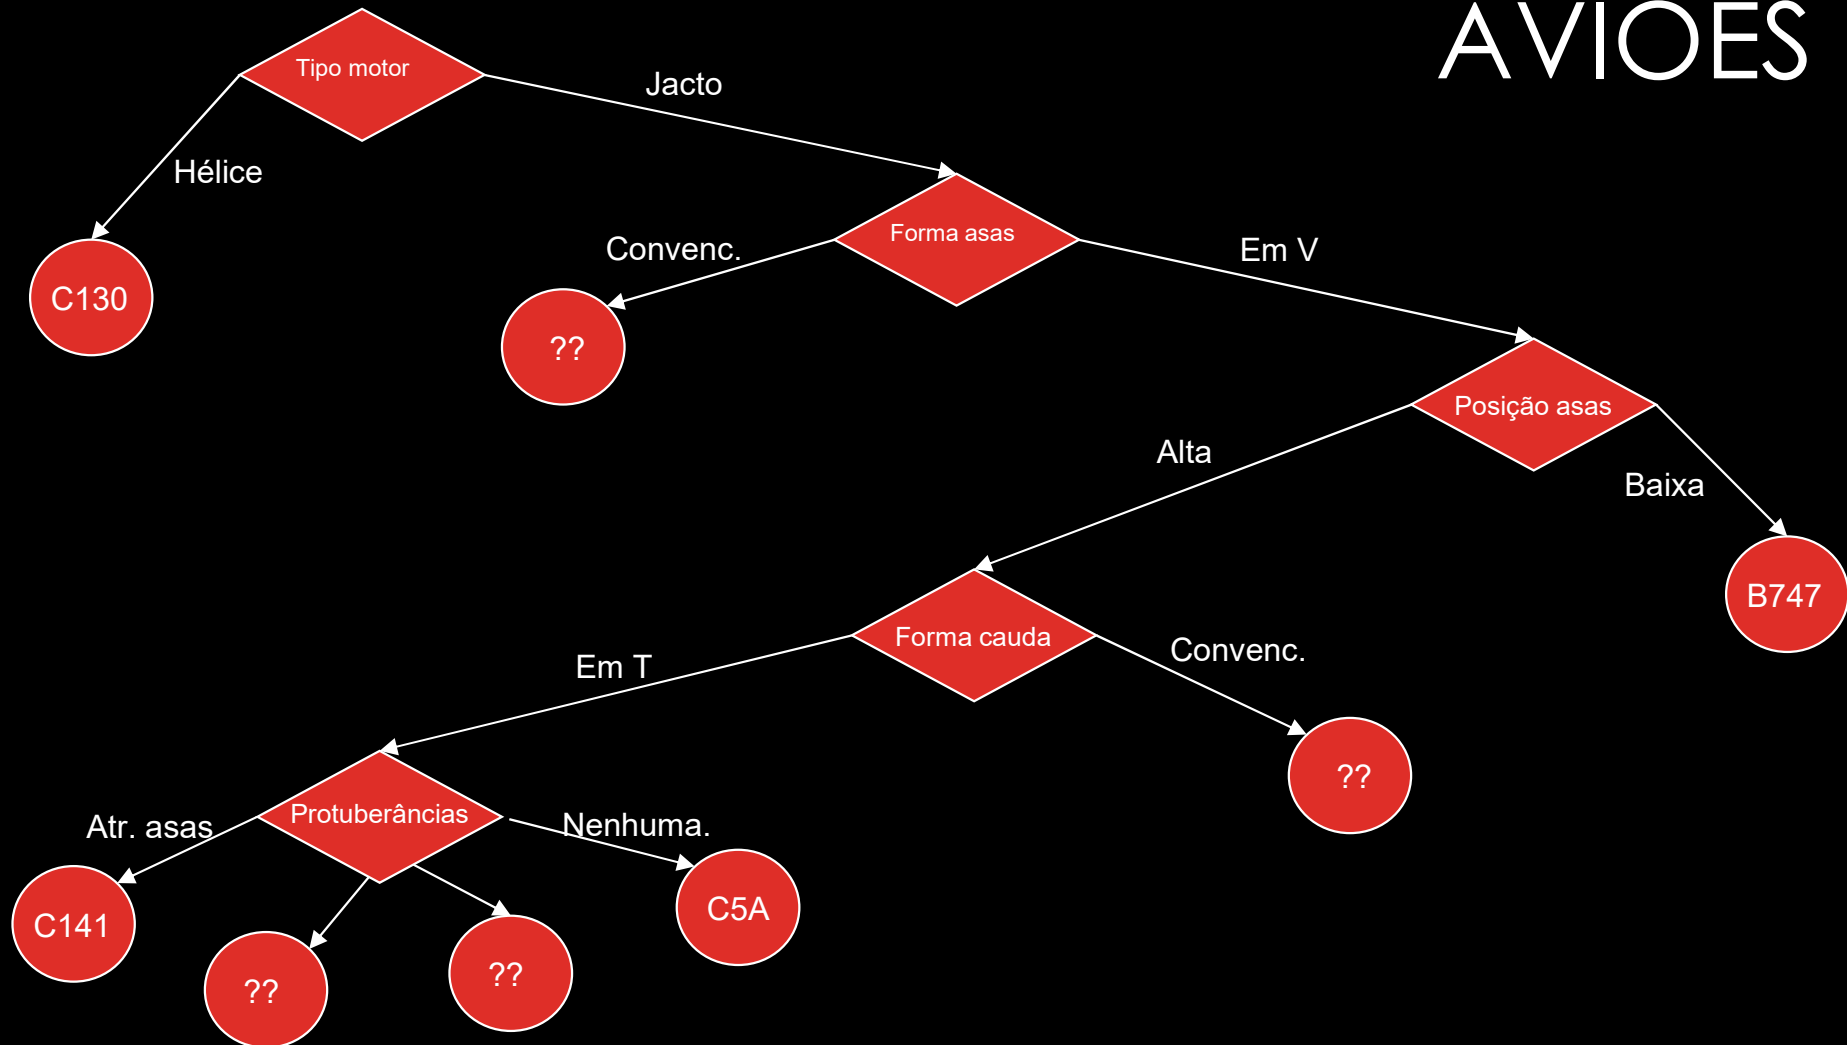
- Cada objecto (dentre 4 classes) tem um conjunto de atributos, como por exemplo (no caso dos aviões):
 - # motores, tipo (jacto, hélice, ...), posição das asas (acima na fuselagem ou abaixo), forma das asas, forma da cauda, comprimento, tara, velocidade, altitude, etc.
 - Depois de identificar um número de atributos é preciso filtrar os que são importantes para suportar o processo de resolução do problema.
 - Usar muitos atributos conduz a espaços de elevada dimensionalidade (maldição da dimensionalidade “*curse of dimensionality*”)
 - Problema da esparsidade dos dados num espaço de elevada dimensionalidade reduz a significância estatística.

ÁRVORES DE DECISÃO

- Nó: representa uma questão acerca do valor de um atributo ou uma conclusão.
- Ramo: representa um dos valores possíveis para o atributo associado ao nó que o origina.

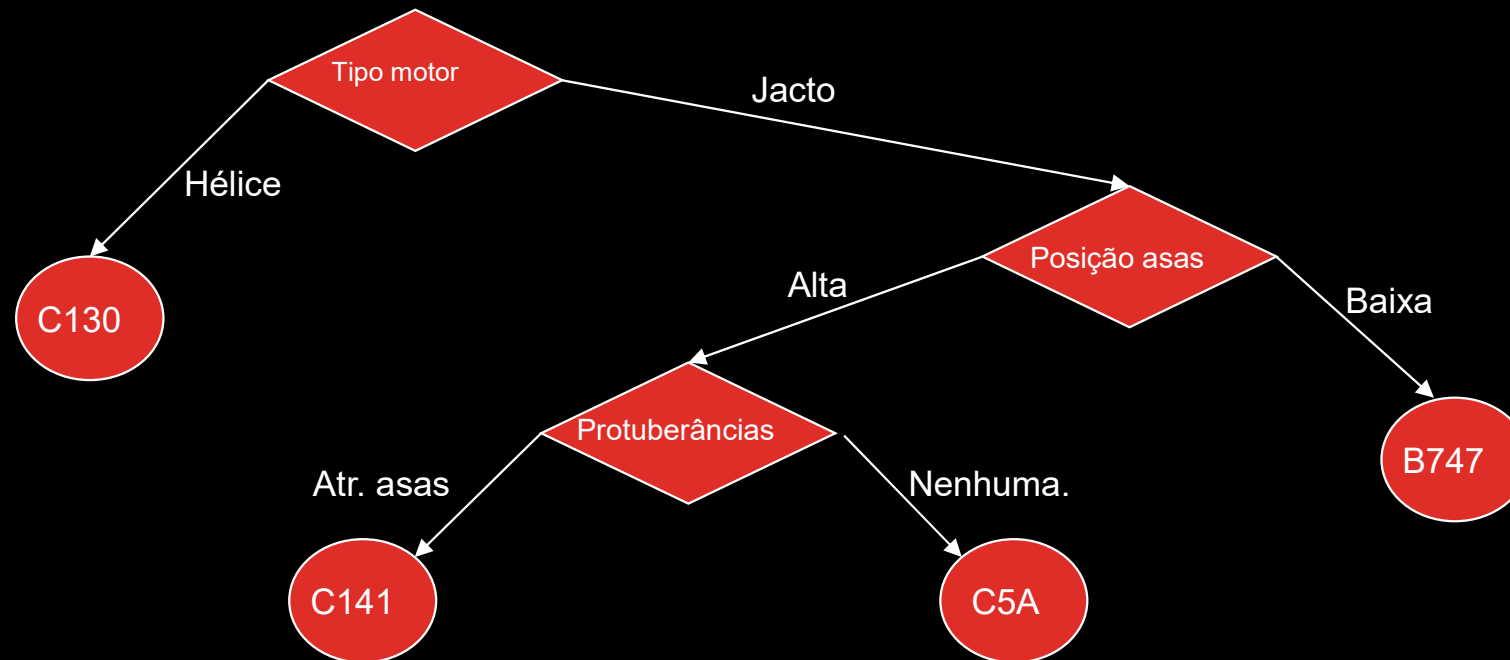
	Tipo do avião			
Atributo	C130	C141	C5A	B747
Tipo motor	Hélice	Jacto	Jacto	Jacto
Posição das asas	Alta	Alta	Alta	Baixa
Forma das asas	Convenc.	Em V	Em V	Em V
Cauda	Convenc.	Em T	Em T	Convenc.
Protuberâncias na fusel.	Sob asas	Atr. Asas	Nenhuma	Atr. cockpit

ÁRVORE DE DECISÃO PARA A IDENTIFICAÇÃO DE AVIÕES



UMA ÁRVORE DE DECISÃO MELHOR

- Reordenando os nós e eliminando ramos que conduzem a conclusões impossíveis (desconhecidas) podemos chegar a uma árvore de decisão simplificada e mais eficaz.



CONVERTER ÁRVORES DE DECISÃO EM REGRAS

- A árvore de decisão anterior não tem nós intermédios. Este aspecto é um pre-requisito para a seguinte abordagem:
 - Definição: uma cadeia é definida como sendo o caminho de um nó para outro em que se atravessa os ramos numa única direcção.
 1. Identificar um nó conclusão ainda não tratado.
 2. Percorrer a cadeia desde a conclusão até à raiz da árvore.
 3. Na cadeia, os nós em círculos são nós THEN (conclusões) enquanto as caixas são nós IF (premissas).
 4. Construir o conjunto de regras de produção para a cadeia em causa e repetir este processo para cada nó conclusão.

EXEMPLO

(regra 1
 (tipo-motor hélice)
=>
 (tipo-aviao C130))

(regra 2
 (tipo-motor jacto)
 (posicao-asas baixa)
=>
 (tipo aviao B747))

(regra 3
 (tipo-motor jacto)
 (posicao-asas alta)
 (protuberancias nenhuma)
=>
 (tipo-aviao C5A))

(regra 4
 (tipo-motor jacto)
 (posicao-asas alta)
 (protuberancias atras-asa)
=>
 (tipo aviao C141))

A ÁRVORE MÍNIMA

Contudo era possível simplificar ainda mais a árvore de decisão, mediante a análise de um único atributo: as protuberâncias.

(convida-se o leitor a definir a árvore de decisão e o correspondente conjunto de regras)

A ordem em que se escolhe os nós determina a geração de árvores de decisão diferentes e de conjuntos de regras diferentes. Em vez de um processo ad-hoc existem abordagens sistemáticas. Por exemplo: o algoritmo ID3 (Quinlan, 1983).

O ALGORITMO ID3

- Algoritmo para a geração sistemática de árvores de decisão mínimas e geração do correspondente conjunto de regras de produção.
- Baseado na noção de minimização da **entropia informacional**.
- Existem programas comerciais que implementam este algoritmo, ou variantes.



John Ross Quinlan
1983

QUANTIFICAÇÃO DA INFORMAÇÃO USANDO ENTROPIA

- “Informação” pode ser vista como uma contribuição para a redução da incerteza.
- Em Teoria da Informação é vulgar usar-se a **entropia** como medida da incerteza, i.e. do inverso da quantidade de informação.
 - Exemplo: Considere-se o problema de adivinhar uma palavra em Português com base no conhecimento da sua primeira letra.
 - Qual a quantidade exata de informação que se obtém quando se fornece a informação de que a palavra começa pela letra A?
 - Será maior ou menor do que se fornecer a informação de que a palavra começa pela letra Z?

ENTROPIA E MICROESTADOS

- Quanto maior o número disponível de possibilidades (microestados de um sistema) maior a sua entropia.
- Exemplo: Considere uma caixa quadrada com 100 bolas (50 brancas e 50 pretas).
 - Quantas possibilidades há de arrumar todas as bolas brancas num retângulo de um lado e todas as bolas pretas do outro? 4
 - E quantas são as possibilidades de arrumação aleatória?
 - Combinações $n p a p = 100! / (50! \times 50!) = 10^{29}$
 - Qual a probabilidade de estar num estado “arrumado”?
- Pode-se reduzir a entropia de um sistema fornecendo energia (sistema físico) organizando-o, ou fornecendo informação (sistema simbólico), i.e. organizando-o!
 - Reduz-se em qualquer caso o número de microestados possíveis.

ENTROPIA E EQUILÍBRIO TERMODINÂMICO: LEI DE BOLTZMANN


- A partir de um estado inicial um sistema tende para estados com maior número de **microestados**, i.e. mais prováveis, até que atinge o estado de máxima probabilidade, ou seja o estado do equilíbrio térmico.
- Aplicando esta conclusão à segunda lei da termodinâmica, a grandeza a que costumamos chamar entropia pode ser identificada com a probabilidade do estado em questão. Este resultado central na obra de Boltzmann habitualmente é representado pela equação seguinte:

$$S = k \log(W)$$

- S representa a entropia, k a constante de Boltzmann, W a "probabilidade termodinâmica" e log o logaritmo natural.
 - A denominação "probabilidade", neste contexto, é enganadora. Ela representa aqui o número de microestados, caracterizados por lugar e impulso de todas as partículas, que correspondem a um estado do sistema abrangente, ou seja, o macroestado, no caso de um gás caracterizado por pressão, volume e temperatura.

REPRESENTAÇÃO LOGARÍTMICA DA ENTROPIA

- A entropia de um estado ou evento elementares deverá ser tanto menor quanto mais a probabilidade de ocorrência (p) se aproxima de 0 ou de 1, sendo máxima quando a probabilidade é 0.5, caso em que: $H = -\log(2^{-1}) = \log(2)$



- Pode-se usar o \log_2 (base 2) ou outra qualquer base do logaritmo.
- Notar que $\log_2(1)=0$ e que $\log_2(0 < x < 1) < 0$ ex.: $\log_2(0.5)=-1$, daí o sinal – que se coloca na fórmula da entropia, para H ser positiva

ENTROPIA INFORMACIONAL: SHANNON

- Se se usar o \log_2 a informação mede-se em *shannon*
1 *shannon* = 1 bit
- A entropia de um sistema de comunicação mede a quantidade de informação média que o sistema transmite em cada mensagem.



Claude Shannon
(ca. 1963)

ENTROPIA DE UMA STRING

- Considere-se uma sequência de estados ou eventos elementares, i.e. uma série de 0s e 1s, o que corresponde a um ficheiro binário, com N bits de comprimento, assumindo que cada bit b tem entropia máxima: $p(b=0)=p(b=1)=0.5$.
- O número de formas possíveis em que os N bits podem ser arrançados é $W=2^N$.
- A expressão de Shannon neste caso origina:

$$H = N \log(2) \Leftrightarrow H = \log(2^N) \Leftrightarrow \mathbf{H = \log(W)}$$

ou seja: a mesma expressão da entropia de Boltzmann, mas em que a constante de Boltzmann seria 1.

ENTROPIA DE UM SISTEMA DE COMUNICAÇÃO

- Comunicação significa transferir informação de um emissor para um recetor.
 - Neste sentido, a mensagem do emissor visa reduzir a entropia do recetor.
- Suponhamos que se pretende transmitir o resultado do lançamento de uma moeda ao ar. Quantos bits têm de ser transmitidos?
 - Qual é a entropia de um lançamento de moeda ao ar?
- Suponhamos que se pretende transmitir uma String.
 - Se uma mensagem contém 3 elementos dentre o conjunto de caracteres {A, B, C, D} e se estes caracteres forem equiprováveis, qual é a quantidade de informação transmitida em BCD? E em ACA?
 - E se o carater A tiver 70% de probabilidade de ocorrência e os restantes 10% cada?

$$H = -\log_2(4^3) = 6 \text{ bits}$$

ENTROPIA DE UM ATRIBUTO NUM SISTEMA DE CLASSIFICAÇÃO

- A entropia de um atributo usado num sistema de classificação varia inversamente com a quantidade de informação que esse atributo fornece ao processo de classificação.
- O ID3 começa por selecionar os nós (atributos) que têm menor entropia.
- A raiz da árvore de decisão é o nó correspondente ao atributo de entropia mínima.

ENTROPIA DO VALOR DE UM ATRIBUTO

Considere-se a existência de várias classes C e considere-se a probabilidade de estarmos perante a classe C_i quando o atributo A_k tem o valor j .

$$p(C_i | a_{k=j}) = p(C_i | a_{k,j}) = x$$

$$H(C_i | a_{k,j}) = -x \log_2 x$$

$$H(C | a_{k,j}) = - \sum_{i=1}^N x \log_2 x$$

ENTROPIA DE UM ATRIBUTO

- A entropia associada a um atributo é a média dos valores das entropias associadas a todos os seus valores possíveis, ponderada pela probabilidade de ocorrência de cada valor.

$$\sum_{j=1}^{M_k} p(a_{k,j}) \cdot H(C|a_{k,j})$$

Em que M_k é o número de valores possíveis do atributo a_k

CÁLCULO DA ENTROPIA DE UM ATRIBUTO NUM SISTEMA DE CLASSIFICAÇÃO

$$H(C|A_k) = \sum_{j=1}^{M_k} p(a_{k,j}) \cdot \left[- \sum_{i=1}^N p(c_i | a_{k,j}) \cdot \log_2 p(c_i | a_{k,j}) \right]$$

$H(C|A_k)$ Entropia da propriedade de classificação do atributo A_k

$p(a_{k,j})$ Probabilidade de o atributo k ter o valor j

$p(c_i | a_{k,j})$ Probabilidade de a classe ser c_i , quando o atributo k tem o valor j

M_k Número total de valores para o atributo A_k

N Número total de classes

K Número total de atributos

A entropia de um atributo é a soma ponderada das entropias relativas a cada um dos seus valores possíveis.

EXEMPLO

- Problema: Investimento em fundos no mercado accionista
- Possibilidades:
 - Blue chips
 - Ouro
 - Produtos financeiros
- Objectivo: determinar, num dado momento, sob um conjunto de condições, o fundo onde que colocar todo o dinheiro.
- 3 *classes* de valor esperado: alto, médio, baixo: as conclusões do sistema pericial.

PROBLEMA DE CLASSIFICAÇÃO

- Características:
 - Tipo de Fundo
 - Taxas de juro
 - Liquidez na Europa, Japão e EUA.
 - Grau de tensão internacional.
- Classes
 - Valor Elevado
 - Valor Médio
 - Valor Baixo

TABELA DE SITUAÇÕES ESPECÍFICAS

Tipo de Fundo	Taxa Juro	Liquidez	Tensão Internacional	Valor do Fundo
Blue chip	Alta	Alta	Média	Médio
Blue chip	Baixa	Alta	Média	Alto
Blue chip	Média	Baixa	Alta	Baixo
Ouro	Alta	Alta	Média	Alto
Ouro	Baixa	Alta	Média	Médio
Ouro	Média	Baixa	Alta	Médio
Produtos Financeiros	Alta	Alta	Média	Baixo
Produtos Financeiros	Baixa	Alta	Média	Alto
Produtos Financeiros	Média	Baixa	Alta	Baixo

APLICAÇÃO DO ID3 AO EXEMPLO

$P(a_{3,1})$ = probabilidade de a liquidez ser alta = 6/9

$P(a_{3,2})$ = 3/9

$P(c_1 | a_{3,1})$ = probabilidade de o valor de um fundo ser alto quando a liquidez é alta = 3/6

$P(c_2 | a_{3,1})$ = 2/6

$P(c_3 | a_{3,1})$ = 1/6

$P(c_1 | a_{3,2})$ = probabilidade de o valor de um fundo ser alto quando a liquidez é baixa = 0/3

$P(c_2 | a_{3,2})$ = 1/3

$P(c_3 | a_{3,2})$ = 2/3

DETERMINAR A ENTROPIA MÍNIMA

$$H(C | liquidez) = (6/9) [-3/6 \log_2(3/6) - 2/6 \log_2(2/6) - 1/6 \log_2(1/6)] \\ + (3/9) [-0/3 \log_2(0/3) - 1/3 \log_2(1/3) - 2/3 \log_2(2/3)] = 1.2787$$

De forma similar tem-se:

$$H(C | juro) = 1.14$$

$$H(C | tensão) = 1.28$$

$$H(C | tipo fundo) = 1.14$$

O empate entre taxa de juro e tipo de fundo pode ser resolvido arbitrariamente. Por exemplo seleciona-se a **taxa de juro**.

ÁRVORE DE DECISÃO

- Sendo o nó raiz a “**Taxa de juro**”, tem que se particionar a tabela de atributos segundo o atributo taxa de juro, o que dá origem a três tabelas (uma para cada valor do atributo).
- Calcula-se de novo a entropia para cada atributo em cada uma das sub-tabelas.
- Neste caso o atributo “**Tipo de fundo**” dá entropia zero nas três subtabelas pelo que é este o segundo atributo escolhido em cada um dos três casos para o valor da “taxa de juro”, sendo a árvore construída com base apenas nestes 2 atributos.

REGRAS DE PRODUÇÃO

- As regras de produção que resultam são do tipo:

Regra 1: **Se** taxas de juro altas
e tipo de fundo é Blue chip
Então o valor do fundo é médio

Regra 2: ... ?

...

Quantas regras? 9

E se fosse com a árvore natural (usando os 4 atributos)? 54